

# < ResNeXT >

Loashtat : 넓이(채널수)나 깊이가 증가보다 Cardinality 증가가 효율적이다

- ResNet을 계승한 모델

residual learning

Inception 모델 유사

→ ResNet + Cardinality

✓ Convolution 연산 쪼개어 계산

✓ Split - Transform - merge

✓ 똑같은 형태의 building block 끼

조각된 CNN 연산을 쪼개어 처리 결과 → Cardinality

Group Convolution (depth는 최소 3 이상)

- width보다 Cardinality를 증가시키는게 효율적

성능  
↑

Cardinality > Width > Depth

# < Xception >

## - Inception module

- cross-channel Correlation 입력채널들간의 관계 학습
- Spatial Correlation filter와 특징채널들 사이의 관계 학습  
(공간적인 특성 학습)

• 1x1 Conv를 통해 Cross-channel Correlation을 살펴봄



• Input data를 원본 공간보다 작은 3,4개의 별도 공간에 mapping



• 이 작은 3D 공간의 모든 상단반경을 3x3, 5x5 Conv로 통해 mapping




"cross-channel Correlation과 Spatial Correlation의  
mapping은 완전히 분리될 수 있다"  
라는 가정

- An "extreme" version of Inception module

↳ Inception에서 더 나아가 Channel, Spatial Conv, depthwise Separable Conv로 완벽히 구분하자.

- Inception module은 large  $|x|$  Conv로 재구성하고  
output channel이 겹치지 않는 부분에 대해서  
Spatial Conv로 재구성



• 학습과정

- 1)  $|x|$  Conv를 통해 Cross-channel Correlation
- 2) 각 output channel에 대해 Spatial Conv 학습

## Depthwise Separable Convolution

↳ 각 채널마다 Spatial feature 추출하기 위한 방식

- Channel-wise Spatial Conv  $\rightarrow$   $1 \times 1$  Conv (수행순서)
- Inception 모듈과 달리, Convolution 사이에 non-linear activation이 없음

⑦3  $\rightarrow$  residual Connection이 있는  
depthwise Separable Convolutional linear stack.

- Xception 활용

$\rightarrow$  DeepLab V3+ Encoder로 Xception 제안

← Attous Convolution  
filter 없이  
인공적으로 두 번  
Conv 수행